

Teorías de la conspiración y discurso de odio en línea

La caja negra de TikTok



Radiografía analítica de la **caja negra** de **TikTok**



Javier Barriuso (Barri)

¿Y si todo fuera parte de un plan?

No te cuentan la verdad



METADATOS

Fecha
Hora
Ubicación
ID dispositivo
Idioma
ID de video
Hashtags
Música
Duración
...

COMENTARIOS

control escapado manipulación
peligroso oculto respuestas
exageración exageración
cobrar verdad manipulación
podría engaño poder
élite programa gobierno estado
observación privacidad aislado

ACTIVIDAD



Objetivos del taller

Cinco pasos para convertir TikTok en una fuente de datos trazable.



> Objetivo

Metadatos estructurales

01

Entender

TikTok como fuente de datos

02

Capturar

Metadatos públicos y trazables

03

Limpiar

Deduplicar y filtrar ruido

04

Analizar

Métricas, texto y relaciones

05

Visualizar

Informe, gráficos y GEXF

Ruta analítica: captura → limpieza → análisis → visualización

TikTok como objeto de investigación

Campos de lectura para formular preguntas investigables.



Cultura digital

Política

Opinión pública

**Preguntas
de investigación**

De un fenómeno social a un corpus analizable

Marketing

Activismo

Desinformación

Como se conecta con TikTok

No usa la API oficial: automatiza navegador y lee endpoints internos web.



Endpoints internos que aprovecha

`/api/search/general/full/`
búsqueda por palabra

`/api/challenge/item_list/`
videos de hashtag

`/api/comment/list/`
comentarios

`/api/comment/list/reply/`
respuestas a comentarios

Punto metodológico

No es API oficial

Depende de la web publica y de una sesión valida.

Tokens del navegador

msToken, X-Bogus y _signature los resuelve el contexto web.

Riesgo técnico

Si TikTok cambia la web, puede romperse la extracción.

Extracción quirúrgica de metadatos en lugar de archivos multimedia pesados



Lo que NO es


Descarga de vídeo crudo



Archivos pesados, difíciles de procesar a gran escala, carentes de contexto numérico e imposibles de analizar de forma estructurada.


Lo que SÍ es

Extracción híbrida de metadatos



Captura quirúrgica de texto, estadísticas de engagement, identificadores de creador y temporalidad. Ligero, estructurado y optimizado para análisis de datos puro.

Un núcleo central alimenta motores de extracción especializados




Tres vías de búsqueda paralelas para garantizar una captura exhaustiva




	Estrategia A: Búsqueda por Texto (API Search)	Estrategia B: Búsqueda por Hashtag (API Challenge)	Estrategia C: Fallback DOM (Navegación simulada)
Mecanismo Interno	Llama a la API /api/search/general/full/ con paginación por offset.	Extrae el challengeID numérico y usa /api/challenge/item_list/ con cursor.	Scroll automatizado extrayendo URLs visibles directamente del HTML.
Qué encuentra	Descripciones o transcripciones que contienen el término, incluso sin hashtags.	Únicamente vídeos que incluyen el hashtag explícito en su etiqueta.	Rescate robusto cuando el servidor bloquea identificadores específicos.
Perfil de Ejecución	Alta velocidad, cobertura semántica amplia.	Alta velocidad, precisión taxonómica.	Baja velocidad, máxima redundancia anti-bloqueo.

El embudo de filtrado convierte el ruido algorítmico en datos limpios



Cada elemento visible de la interfaz equivale a una variable rastreada



El rastro invisible del tiempo codificado en cada identificador

Decoding the ID

Variable: video_id (Snowflake ID)

7643804276275547415

Los primeros 32 bits ocultan un
Timestamp Unix.
Decodificado: 18-05-2026 09:14:33

Temporal Context



Variable: video_fecha

La extracción se registra obligatoriamente en formato UTC
(Tiempo Universal Coordinado). Para aplicaciones **estratégicas
locales**, requiere conversión manual post-extracción (Ej.
CET/CEST para España requiere añadir +1 o +2 horas).



Indicadores de viralidad capturados como una instantánea temporal



Alcance Base

video_vistas



Aprobación

video_likes



Propagación

video_compartidos



Conversación

video_comentarios



Retención

video_guardados

Guardrail

REGLA DEL SISTEMA: Estas cifras representan una 'fotografía' exacta en el segundo de la extracción. Un vídeo analizado con 1,000 visualizaciones hoy puede registrar 500,000 en una extracción repetida mañana.

Construyendo métricas de alto valor mediante combinación de variables



Tasa de Engagement



$$\frac{(\text{video_likes} + \text{video_comentarios} + \text{video_compartidos} + \text{video_guardados})}{\text{video_vistas}} \times 100$$

- El verdadero indicador de resonancia comunitaria, estandarizando el rendimiento más allá del mero alcance visual.



Ratio de Aprobación



$$\frac{\text{video_likes}}{\text{video_vistas}}$$

- Diferencia analíticamente el contenido genuinamente apreciado del contenido 'hate-watched' (altamente visualizado por polémica pero carente de validación social).

Dimensiones de análisis: Convirtiendo columnas en respuestas estratégicas



Análisis Temporal

○ [video_fecha] + [video_vistas]

¿En qué momento exacto se volvió viral un tema y existen picos de volumen coincidentes con noticias del mundo real?

Análisis de Creadores

[username] + [author_verified] ○

¿El volumen de conversación lo impulsan cuentas oficiales establecidas o un enjambre descentralizado de micro-creadores?

Ecosistema de Contenido

○ [hashtags] + [music_title]

¿Qué clústeres temáticos secundarios y matrices de audio viral coexisten alrededor de nuestra palabra clave principal?

Análisis de Formato

[video_width vs height] + [video_duracion_seg]

¿Predomina en la audiencia el contenido efímero vertical rápido (<30s) o narrativas largas grabadas horizontalmente?

Reglas del ecosistema y restricciones del servidor de origen



Límite del Servidor

○ Capacidad máxima truncada

Capacidad máxima truncada (Top 2.000 – 5.000 resultados). Para hashtags masivos, la API descarta el histórico profundo, priorizando la viralidad reciente.

Filtro Contains Estricto

Precisión vs Alcance ○

Descartamos contenido etiquetado etiquetado preventivamente como “relacionado” por la IA si no contiene explícitamente el término exacto buscado.

Desfase Temporal

○ Métricas Fotográficas

El engagement refleja un segundo exacto. Requiere ejecuciones de script recurrentes para mapear tendencias dinámicas reales.

Entidades Borradas

○ Puntos Ciegos del Sistema

Vídeos eliminados por el creador o purgados o purgados por moderación antes de la extracción desaparecen sin dejar metadatos rastreables.

Dos estructuras de salida para dos perfiles de consumo de datos



Perfil Analista de Negocio

Formato: .CSV (UTF-8)

[video_id]	[fecha]	[vistas]	[likes]	[shares]	[comentarios]
...	...	...	...	...	...
...	...	...	...	...	...
...	...	...	...	...	...
...	...	...	...	...	...
...	...	...	...	...	...

Cuadrícula tabular ordenada y legible. Optimizada para pivotar en Excel, graficar en Tableau o alimentar inteligencias artificiales de texto.


Perfil Desarrollador / Data Scientist

Formato: .JSON Jerárquico

```
{  "data": [
  {
    "video_id": "...",
    "metadata": {
      "timestamp": "...",
      "duration": ...,
      "author": {
        "username": "...",
        "verified": true
      }
    },
    "metrics": {
      "views": ...,
      "engagement": {
        "likes": ...,
        "shares": ...,
        "comments": ...
      }
    }
  }
]
```

Estructura de datos anidada nativa. Lista para ingesta directa en pipelines de Python, entornos R o APIs de visualización programática masiva.

De un flujo de contenido efímero a un activo de inteligencia estructurada



El **scraping ético y técnico de metadatos** permite **eludir la opacidad algorítmica**. Al aislar las variables matemáticas del archivo de vídeo multimedia, transformamos el ruido caótico de interacciones virales en un marco de datos **determinista, auditable** y listo para la toma de decisiones estratégicas de alto nivel.

Ética, legalidad y trazabilidad

Marco mínimo para recopilar, documentar y presentar datos públicos.



01

Minimización

Recopilar solo lo necesario

02

Anonimización

Proteger a los usuarios en capturas y ejemplos

03

Trazabilidad

Fecha, criterio, versión y límites

04

Finalidad

Uso académico y proporcional

Regla

Lo técnicamente posible no sustituye el criterio ético y metodológico.

Comentarios como conversación medible



username	video_url	video_fecha	vistas	likes	comentario
usuario_001	https://...	2026-05-21	12500	830	Me parece muy interesante
usuario_002	https://...	2026-05-22	8200	510	No estoy de acuerdo
usuario_003	https://...	2026-05-23	44200	2200	Alguien tiene la fuente?
usuario_004	https://...	2026-05-24	17300	760	Esto se esta moviendo mucho

autor_handle

comentario

likes

video_url

username

Lectura analítica

Los comentarios conectan texto, recepción y relaciones entre cuentas.

Análisis textual



hashtags sentimiento datos video
red análisis muestra grafo
likes comentarios
investigación usuarios
métrica comunidad engagement
TikTok

Normalizar el texto

Eliminar el ruido


Contar términos

**Contrastar
cualitativamente**

Análisis de sentimiento con IA



Distribucion de sentimiento



Uso

Ordenar grandes volúmenes de comentarios


Cautela

Ironía, jerga y contexto pueden alterar los resultados

Método

Validar mediante la lectura de ejemplos

Grafo de relaciones



Nodo

Cuenta

Arista

Interacción

Peso

Repetición

Comunidad

Grupo denso

Programa real: tres fases operativas

Flujo de trabajo: extraer, analizar y convertir los resultados en visualizaciones.



Fase 1

Scraping

Usuarios, hashtags y comentarios



Fase 2

Análisis

Publicaciones, comentarios y sentimiento



Fase 3

Visualización

Informe HTML, GEXF y gráficos

Entrada del programa

```
python menu.py
```

Menú principal

Gestiona de forma mas sencilla todo el programa



TikTok OSINT & Analytics Toolkit

TikTok OSINT & Analytics ToolkitScraping · Análisis · Visualización

0. Configuración — Iniciar sesión y guardar cookies

Haz esto primero para evitar bloqueos de TikTok

Fase 1 — Captura de datos

Fase 2 — Análisis

Fase 3 — Visualización

Otros

1. Scraper de Usuario

Perfil @user

2. Scraper de Hashtag

Por palabra / hashtag

3. Scraper Comentarios

Miles de comentarios (Pro)

4. Edad de Cuentas

Antigüedad de comentaristas

5. Analítica Publicaciones

Vistas y likes

6. Analítica Comentarios

Nubes de palabras

7. Sentimiento con IA (Comentarios)

RoBERTa · Grog · Mistral

8. Gráficas Multidimensionales de Comentarios

Sesga · Arquetipo · Intención · Pain points

9. Patrones de Cuentas / Bots

Antigüedad · actividad · perfiles vacíos

10. Informe HTML

Elige proyecto o genera + abre informe

11. Grafo de Redes

6EXF para Gephi

12. Carpeta Outputs

Ver resultados generados

13. Carpeta Proyecto

Raíz del proyecto

Listo. Selecciona una opción.

Salir

Práctica 1: preparar el entorno



Arrancar el proyecto y guardar la sesión antes de extraer datos.

Objetivo

Preparar el entorno y comprobar que el menú se abre correctamente.

- 01 **Abrir una terminal**
- 02 Ir a la carpeta del proyecto
- 03 Abrir el menú
- 04 Guardar la sesión

Preparar el entorno

```
cd H:/1-TikTok  
python menu.py  
python src/scrapers/1-guardar_sesion.py
```

Antes de extraer datos: confirmar rutas, entorno y sesión activa.

Práctica 1: preparar el entorno



Arrancar el proyecto y guardar la sesión antes de extraer datos.

Objetivo

Preparar el entorno y comprobar que el menú se abre correctamente.

- 01 **Abrir una terminal**
- 02 Ir a la carpeta del proyecto
- 03 Abrir el menú
- 04 Guardar la sesión

Preparar el entorno

```
cd H:/1-TikTok  
python menu.py  
python src/scrapers/1-guardar_sesion.py
```

Antes de extraer datos: confirmar rutas, entorno y sesión activa.

Práctica 2: extraer datos



Del CSV de usuarios a los comentarios exportados para su análisis.



Extraer datos

```
python scripts/scraper.py --test data/usuarios.csv
```

Práctica 3: analizar y visualizar

Transformar publicaciones y comentarios en resultados interpretables.



01

Analítica de publicaciones

Métricas, volumen y comportamiento de piezas.

02

Analítica de comentarios

Texto, interacciones y señal conversacional.

03

Informe HTML

Resumen navegable para revisar resultados.

Analizar no consiste solo en ejecutar: exige leer ejemplos y contrastar resultados.

Práctica 4: crear el grafo

Convertir comentarios en relaciones para explorar comunidades e interacciones.

Crear grafo

```
python src/visualization/crear_gexf.py
```

01


Seleccionar el CSV de comentarios

02

Generar el archivo .gexf

03

Abrir el archivo .gexf en Gephi



Interacción → arista
Repetición → peso
Grupo denso → comunidad



Cierre: de metodología a investigación

Lo importante es que el proceso pueda explicarse, repetirse y defenderse.



01

Criterio de búsqueda

02

Fecha y hora

03

Tamaño de la muestra

04

Filtros aplicados

05

Límites

06

Hallazgos

Resultado esperado


Una metodología defendible, no solo una demostración técnica.

© 2011 Blackwell Publishing Ltd *Journal of Internal Medicine* 270: 255–264




Visualizaciones: comentarios


Actividad de cuentas, concentración de conversación, vocabulario y emojis.



Concentración por cuentas



Comentaristas activos




Palabras frecuentes




Emojis frecuentes

Visualizaciones: comentarios IA


Polaridad, sesgo, arquetipos e indicadores discursivos estimados por IA.




Distribución de sentimiento



Sesgo x sentimiento



Arquetipos de comentario




Puntos de dolor

Mapa de dependencias: qué dato alimenta cada paso

 proceso dato/CSV

Lee cada flecha: la caja amarilla indica el archivo o dato que debe existir antes de ejecutar la caja siguiente.



Orden recomendado

0 → 1/2 → 3 → (5, 6, 7 y 4 en paralelo) → 8 y 9 → 10 y 11

Si falta una gráfica, sigue hacia atrás la flecha de entrada hasta encontrar el CSV que falta.